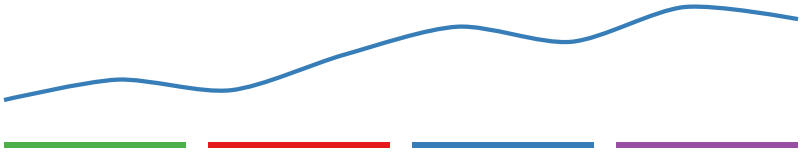
RELATÓRIO DE AVALIAÇÃO · PROJETO DE PORTFÓLIO



Assistente do relatório Gestão Hospitalar no SUS-SP

Quanto um assistente com RAG acerta, medido com intervalo de confiança e comparação pareada

Relatório-fonte de 174 páginas e 60 Perguntas
Rodada principal, com os Veredictos do Juiz revisados pelo autor

Autoria

João Eduardo Pastori Garcia
Estatístico responsável

LinkedIn · GitHub

São Paulo – SP
Novembro de 2026

Sumário

1 O problema **2**

2 O assistente **2**

3 O desenho da avaliação **3**
3.1 Perguntas, Gabarito e Revisão 3
3.2 As três Condições 3
3.3 As medidas 4
3.4 O Veredicto: regra, Juiz e Revisão 4
3.5 Pré-registro 4

4 Resultados com intervalos **5**

5 Comparação pareada **6**

6 Erros por Tipo de pergunta **6**

7 Tokens e latência **7**

8 Variabilidade entre Rodadas **8**

9 Limitações **9**

A Como refazer os números **10**

1 O problema

Quase todo assistente com RAG (geração aumentada por recuperação) que se vê em portfólio é uma demonstração sem medida: ele "parece responder bem", mas ninguém sabe com que frequência acerta, nem se o acerto vem da busca no texto consultado ou do que o modelo de linguagem já sabia antes de ler qualquer coisa. Este projeto constrói um assistente que responde, em português, perguntas sobre um relatório de pesquisa, o Relatório-fonte, e mede quanto ele acerta com as ferramentas de um estatístico: intervalo de confiança, comparação pareada e um desenho fixado antes de olhar a prova.

O texto consultado, chamado aqui de **Relatório-fonte**, é o relatório "Gestão Hospitalar no SUS-SP", um PDF com publicação autorizada e 174 páginas numeradas, além da capa. Um gestor de saúde pergunta, por exemplo, quanto mudou um indicador numa rede de hospitais, e o assistente responde em uma a três frases, cita a Página impressa de onde tirou a resposta e mostra os Trechos em que se apoiou. Quando o Relatório-fonte não trata do assunto, o comportamento certo é dizer isso, e não inventar um número.

A pergunta do projeto tem três partes, e cada uma vira uma medida deste Relatório de avaliação:

1. **Quanto o assistente acerta?** O Acerto da resposta nas Perguntas respondíveis, com intervalo de Wilson, e não um número solto.
2. **O acerto vem da busca?** A mesma prova é feita sem RAG, com o modelo respondendo só com o que já sabe, e as duas Condições são comparadas Pergunta a Pergunta.
3. **Se o Relatório-fonte cabe inteiro no contexto do modelo, para que RAG?** Uma terceira Condição põe o Relatório-fonte inteiro no prompt, e o custo de cada Condição é medido em tokens de entrada e em latência.

> **O que este Relatório de avaliação entrega**
>
> O número de destaque é o Acerto da resposta com RAG nas 50 Perguntas respondíveis, com o intervalo de confiança de 95%, ao lado do mesmo acerto sem RAG. Não se usa um "acerto geral" sobre todas as 60 Perguntas: sem RAG, abster-se de tudo inflaria essa taxa, porque a Abstenção é a resposta certa nas Perguntas sem resposta. Cada número impresso aqui sai de um script e pode ser refeito a partir das Rodadas versionadas.

O texto usa um vocabulário fixo, definido no glossário do repositório. Os termos com inicial maiúscula (Pergunta, Trecho, Condição, Rodada, Gabarito, Revisão, Veredicto, Juiz, Classe de erro) têm sempre o mesmo sentido.

2 O assistente

O assistente é um pipeline de cinco passos. Todos rodam a partir de scripts versionados, e só o último chama um modelo de linguagem.

Extração. O `pdfplumber` lê o Relatório-fonte página a página, com normalização Unicode (NFKC) para desfazer as ligaduras e com a hifenização de fim de linha desfeita. Cada linha é classificada pelo layout do LaTeX em que o Relatório-fonte foi escrito: corpo, título de capítulo, título de seção ou legenda. As tabelas são detectadas à parte e serializadas linha a linha, com cada célula acompanhada do nome da sua coluna; uma tabela que continua na página seguinte herda a legenda. A capa fica fora. A extração somou 60.370 palavras, 28 blocos de tabela e 104 legendas de figura.

Quebra em Trechos. O texto vira Trechos, os pedaços que o assistente pode recuperar. Nenhum Trecho atravessa a fronteira de página, para que a citação aponte uma página só. Um parágrafo que cabe no alvo de 180 palavras vai inteiro; um maior é dividido por frase, com até 30 palavras repetidas entre Trechos vizinhos da mesma página e seção. O título da seção abre cada Trecho, e cada tabela e cada legenda formam Trechos próprios. São 570 Trechos: 390 de texto corrido, 71 de tabela e 109 de legenda.

Busca. Cada Trecho vira um vetor do modelo `intfloat/multilingual-e5-large`, rodado localmente pelo `fastembed`, sem API paga. O índice é o FAISS com busca exata (`IndexFlatIP` sobre vetores normalizados, ou seja, cosseno exato). Com poucas centenas de Trechos, a busca exata custa quase nada e é determinística: a mesma Pergunta recupera sempre os mesmos Trechos, o que torna o Acerto da recuperação reprodutível. Na Condição com RAG, os 6 Trechos mais próximos da Pergunta vão ao modelo, cada um marcado com a sua Página e o seu tipo (texto, tabela ou legenda).

Resposta. O respondedor é o `gemini-3.5-flash-lite`, do Google, chamado pela API do Google AI Studio com saída estruturada por JSON Schema: a resposta, as páginas citadas e um campo que marca a Abstenção. O prompt manda copiar os números como estão no Relatório-fonte, no formato brasileiro, e não menciona nenhum fato do Relatório-fonte, o que vazaria a resposta na Condição sem RAG. Cada resposta registra o modelo que de fato respondeu, os tokens e a latência.

API e Docker. O assistente é servido por uma API FastAPI, com POST `/perguntar` e GET `/saude`, empacotada em Docker. O modelo de embeddings e o índice ficam em volumes, fora da imagem, e são criados na primeira subida. O CI roda o lint, os testes e o build da imagem a cada envio ao repositório.

3 O desenho da avaliação

3.1 Perguntas, Gabarito e Revisão

A prova tem 60 Perguntas: 50 respondíveis, divididas em 5 Tipos de pergunta conforme o lugar onde a resposta está (número na prosa, número em tabela, número em legenda, conceito ou método, e síntese entre páginas), e 10 sem resposta no Relatório-fonte, em que o certo é a Abstenção. As respondíveis foram espalhadas pelos capítulos em proporção ao volume de texto.

As Perguntas e o Gabarito de cada uma (a resposta certa e as páginas que a sustentam) foram **propostos com ajuda de um modelo de linguagem e conferidos pelo autor** diretamente no Relatório-fonte, linha a linha. Essa conferência é a Revisão: o script de avaliação recusa um Gabarito com qualquer linha sem ela e lista as pendentes. Antes da Revisão, uma conferência mecânica compara o Gabarito com o texto extraído (formato, páginas existentes, valores presentes na página citada) para pegar erro grosseiro. Quando a mesma resposta aparece em mais de uma página (o sumário executivo e a conclusão repetem achados dos capítulos), o Gabarito lista todas, para que uma citação certa não conte como errada.

3.2 As três Condições

As mesmas Perguntas passam pelo mesmo modelo em três Condições, que mudam só o que o modelo recebe:

- **com RAG**: os 6 Trechos recuperados pela busca;
- **sem RAG**: nada do Relatório-fonte, só a Pergunta; mede o que o modelo já sabe, ou acha que sabe;

- **contexto completo**: o texto inteiro do Relatório-fonte, página por página, no prompt de sistema, com o cache de prompt da API.

A comparação principal é com RAG contra sem RAG: ela responde quanto do acerto vem da busca. A comparação com o contexto completo responde se a busca ainda se justifica quando o Relatório-fonte cabe na janela do modelo.

3.3 As medidas

Cada Pergunta, em cada Condição, recebe três medidas binárias, e cada taxa sai com o intervalo de Wilson de 95%, que se comporta bem com amostras pequenas e taxas perto dos extremos:

- **Acerto da resposta**, a medida principal: o conteúdo da resposta coincide com o Gabarito;
- **Acerto da citação**: alguma página citada está entre as páginas do Gabarito;
- **Acerto da recuperação**: alguma página do Gabarito está entre as dos Trechos recuperados; só existe na Condição com RAG, e separa problema de busca de problema de leitura.

As Perguntas respondíveis e as sem resposta são contadas em separado. Nas sem resposta, a medida é a Abstenção correta. Cada resposta errada recebe uma Classe de erro, derivada das medidas, sem julgamento novo, e as Classes são mutuamente exclusivas: **resposta inventada** (respondeu a uma Pergunta sem resposta), **citação errada** (a resposta está certa, a página não), **abstenção indevida** (absteve-se numa respondível), **falha de recuperação** (errou e a busca não trouxe nenhuma página do Gabarito) e **falha de leitura** (errou com a página certa em mãos, ou numa Condição que não recupera).

3.4 O Veredicto: regra, Juiz e Revisão

Os Tipos número na prosa, número em tabela e número em legenda têm resposta numérica. Para essas Perguntas, o Veredicto sai de uma regra determinística: todos os valores do Gabarito precisam aparecer, exatamente, na resposta. A regra é estrita de propósito, porque o prompt manda copiar os números como estão. Quando ela reprova, a resposta vai também ao Juiz, para pegar o falso negativo da regra (uma diferença expressa com o sinal trocado e a palavra "para baixo", por exemplo). As respostas descritivas vão sempre ao Juiz, um modelo de linguagem que compara o conteúdo com o Gabarito e ignora as páginas. O Juiz usou 3 modelos em cadeia, nesta ordem: gemini-3.6-flash, gemini-3-flash-preview e gemini-3.1-flash-lite; quando a cota diária gratuita de um acabava, o seguinte assumia.

O Juiz não tem a última palavra. Na Rodada principal, ele deu 42 Veredictos, e o autor os conferiu numa folha; a Revisão vence o Juiz. Foram 42 Veredictos revisados, e a Revisão concordou com o Juiz em todos. A análise final se recusa a publicar enquanto houver Veredicto do Juiz sem Revisão.

3.5 Pré-registro

O número de Trechos recuperados, o tamanho do Trecho, os modelos, o nível de raciocínio e os prompts ficam num arquivo versionado de parâmetros. Eles foram ajustados só com Perguntas de desenvolvimento, que nunca entram no Gabarito, e congelados por commit antes da Rodada principal: ajustar o sistema olhando a prova inflaria a taxa de acerto. O script de avaliação recusa a Rodada principal enquanto os parâmetros não estiverem congelados e commitados. A Rodada principal foi retomada e registrou os 3 commits em que rodou, todos com os mesmos parâmetros congelados: 85d3e4c, fc1a063 e ad0ad19.

> **As regras de confiança viram código**
>
> - A avaliação recusa um Gabarito com qualquer linha sem Revisão.

- A Rodada principal recusa parâmetros que não estejam congelados por commit.
- Todo Veredicto do Juiz passa pela Revisão do autor antes de virar resultado.
- Todo número impresso sai de um registro alimentado por script, e um conferidor falha diante de número digitado no README ou neste Relatório de avaliação.

4 Resultados com intervalos

A Tabela 1 traz as três medidas nas três Condições, cada uma com o intervalo de Wilson. A Rodada principal fez 180 respostas (cada Pergunta em cada Condição). As três primeiras colunas valem para as 50 Perguntas respondíveis; a última, para as 10 sem resposta. O Acerto da recuperação só existe com RAG.

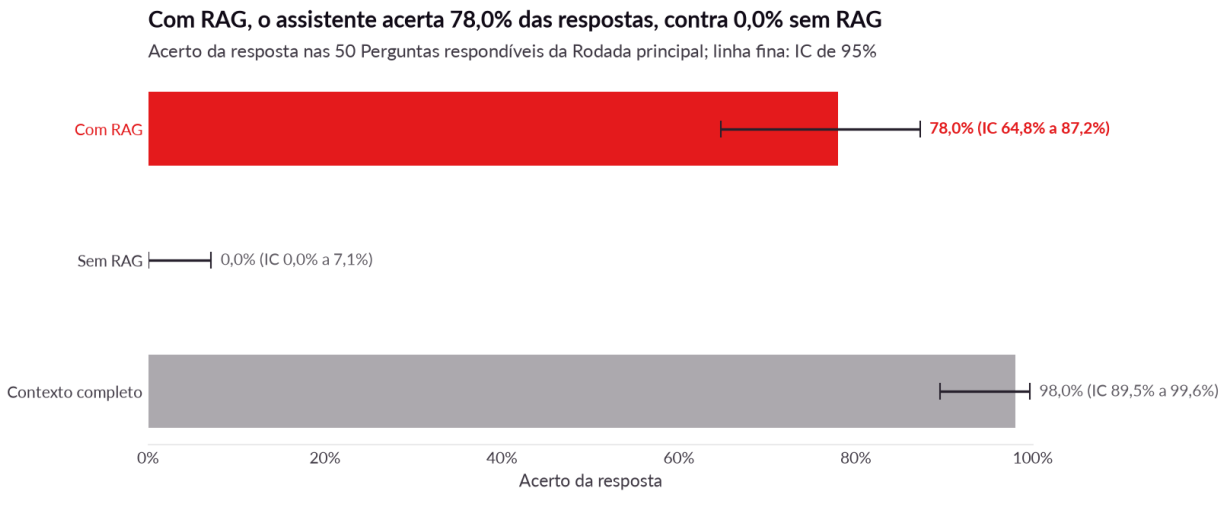
Tabela 1: As medidas por Condição, na Rodada principal, com o intervalo de Wilson de 95% entre parênteses. Acertos da resposta, da citação e da recuperação sobre as Perguntas respondíveis; Abstenção correta sobre as Perguntas sem resposta.

Condição	Acerto da resposta	Acerto da citação	Acerto da recuperação	Abstenção correta
Com RAG	78,0% (64,8% a 87,2%)	82,0% (69,2% a 90,2%)	86,0% (73,8% a 93,0%)	100,0% (72,2% a 100,0%)
Sem RAG	0,0% (0,0% a 7,1%)	0,0% (0,0% a 7,1%)	—	100,0% (72,2% a 100,0%)
Contexto completo	98,0% (89,5% a 99,6%)	86,0% (73,8% a 93,0%)	—	100,0% (72,2% a 100,0%)

O número de destaque

Com RAG, o Acerto da resposta foi de 78,0% nas 50 Perguntas respondíveis (IC de 95%: 64,8% a 87,2%), contra 0,0% sem RAG. Pelo intervalo da diferença pareada (Seção 5), a leitura é: com RAG acerta mais.

A Figura 1 mostra o mesmo Acerto da resposta, com a linha fina marcando o intervalo. O título da figura é escolhido pelo script a partir do resultado, e afirma o achado que os números sustentam.



Fonte: Rodada principal da avaliação do assistente sobre o Relatório-fonte Gestão Hospitalar no SUS-SP, com os Veredictos revisados pelo autor.

Figura 1: Acerto da resposta nas Perguntas respondíveis, por Condição, com o intervalo de Wilson de 95%. A Condição com RAG sai na cor de destaque, e as outras em cinza.

Dois cuidados de leitura. Primeiro, intervalos que se sobrepõem não provam que duas Condições empatam, nem intervalos separados bastam para compará-las: as Condições responderam às mesmas Perguntas, e a comparação certa é a pareada, da próxima seção. Segundo, o Acerto

da citação mede só se a página citada está entre as do Gabarito, e por isso pode ser alto mesmo numa Condição que não recebe o texto, se o modelo souber ou adivinhar a página.

5 Comparação pareada

Como as três Condições responderam às mesmas Perguntas, cada comparação usa os pares: para cada Pergunta respondível, as duas Condições acertam, só uma acerta, ou as duas erram. Só os pares discordantes informam a diferença. O teste é o de McNemar exato, sobre os pares discordantes, e o intervalo da diferença pareada entre os acertos é o de Newcombe (método do escore, para proporções pareadas), também de 95%.

Tabela 2: Comparação pareada do Acerto da resposta nas Perguntas respondíveis da Rodada principal. A diferença é com RAG menos a outra Condição, em pontos percentuais, com o intervalo de Newcombe de 95%; o valor-p é o do teste exato de McNemar.

Comparação	As duas acertam	Só com RAG acerta	Só a outra acerta	As duas erram	Diferença (IC de 95%)	Valor-p (McNemar)
Com RAG × sem RAG	0	39	0	11	78,0 p.p. (63,0 p.p. a 87,2 p.p.)	< 0,001
Com RAG × contexto completo	38	1	11	0	−20,0 p.p. (−33,5 p.p. a −7,0 p.p.)	0,006

Na comparação principal, foram 50 pares: em 39 deles só a Condição com RAG acertou, e em 0 só a Condição sem RAG acertou. A diferença pareada foi de 78,0 p.p. (IC de 95%: 63,0 p.p. a 87,2 p.p.), com valor-p de McNemar < 0,001. Contra o contexto completo, os pares discordantes ficaram assim: 1 a favor de com RAG e 11 a favor do contexto completo; a diferença foi de −20,0 p.p. (IC: −33,5 p.p. a −7,0 p.p.), com valor-p 0,006.

> **O que o intervalo pareado permite dizer**
>
> - Com RAG contra sem RAG: com RAG acerta mais.
> - Com RAG contra contexto completo: com RAG acerta menos.
>
> A leitura segue o intervalo da diferença: todo acima de zero, todo abaixo de zero, ou contendo o zero. Quando o intervalo contém o zero, o resultado é declarado como empate não resolvido, e não como prova de igualdade.

6 Erros por Tipo de pergunta

A Tabela 3 cruza as Classes de erro com o Tipo de pergunta, na Condição com RAG. Em cada linha estão o número de Perguntas do Tipo, os acertos e as respostas em cada Classe de erro. A resposta inventada só pode acontecer nas Perguntas sem resposta, e as outras Classes, só nas respondíveis; daí os traços. A citação errada conta respostas certas com a página errada, e por isso uma linha pode somar mais erros que Perguntas erradas.

Tabela 3: Classes de erro por Tipo de pergunta, na Condição com RAG, Rodada principal. Na linha das Perguntas sem resposta, os acertos são as Abstenções corretas.

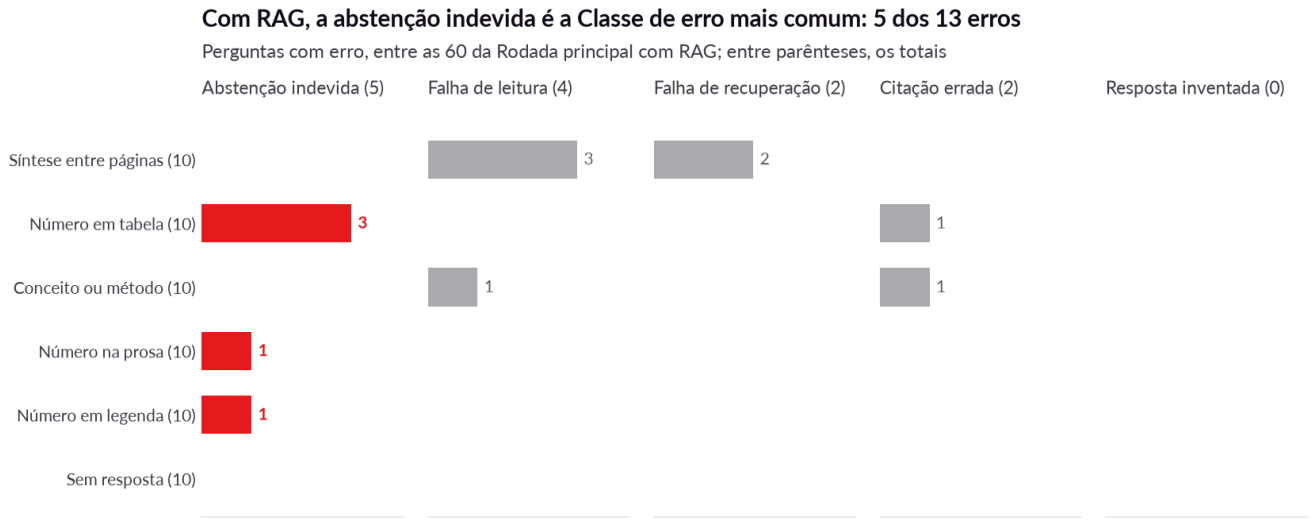
Tipo de pergunta	n	Acertos	Falha de recuperação	Falha de leitura	Abstenção indevida	Citação errada	Resposta inventada
Número na prosa	10	9	0	0	1	0	—
Número em tabela	10	7	0	0	3	1	—
Número em legenda	10	9	0	0	1	0	—
Conceito ou método	10	9	0	1	0	1	—
Síntese entre páginas	10	5	2	3	0	0	—
Sem resposta	10	10	—	—	—	—	0

As Classes separam as causas que pedem correções diferentes. A falha de recuperação aponta para a busca: o Trecho certo não chegou ao modelo, e o remédio seria mudar o número de Trechos, o tamanho do Trecho ou o modelo de embeddings. A falha de leitura aponta para o modelo: o Trecho certo estava lá, e a resposta saiu errada. A abstenção indevida e a resposta inventada são as duas faces da calibração: abster-se demais ou de menos.

A Classe de erro mais frequente com RAG

- Classe mais frequente: abstenção indevida.
- Respostas nessa Classe (em cada uma, se houver empate): 5.
- Respostas com alguma Classe de erro, nas respondíveis e nas sem resposta: 13.

A Figura 2 mostra o mesmo cruzamento, um painel por Classe de erro, com a Classe mais frequente em destaque.



Fonte: Rodada principal da avaliação do assistente sobre o Relatório-fonte Gestão Hospitalar no SUS-SP, com os Veredictos revisados pelo autor.

Figura 2: Classes de erro por Tipo de pergunta, na Condição com RAG. Cada painel é uma Classe; as barras contam Perguntas. Entre parênteses, o número de Perguntas do Tipo e o total de erros da Classe.

Com poucas Perguntas por Tipo, a diferença entre dois Tipos raramente sai do ruído: a tabela serve para apontar onde olhar primeiro, e não para ordenar os Tipos com confiança.

7 Tokens e latência

Sem fatura em dólar por Pergunta, o custo de cada Condição é medido em tokens de entrada, que é o que cresce com o texto enviado ao modelo, e a espera, em latência por Pergunta. Por construção, a Condição contexto completo envia o texto inteiro do Relatório-fonte a cada Pergunta; o cache de prompt da API reaproveita esse prefixo, e os tokens lidos do cache somaram 0 na Rodada principal.

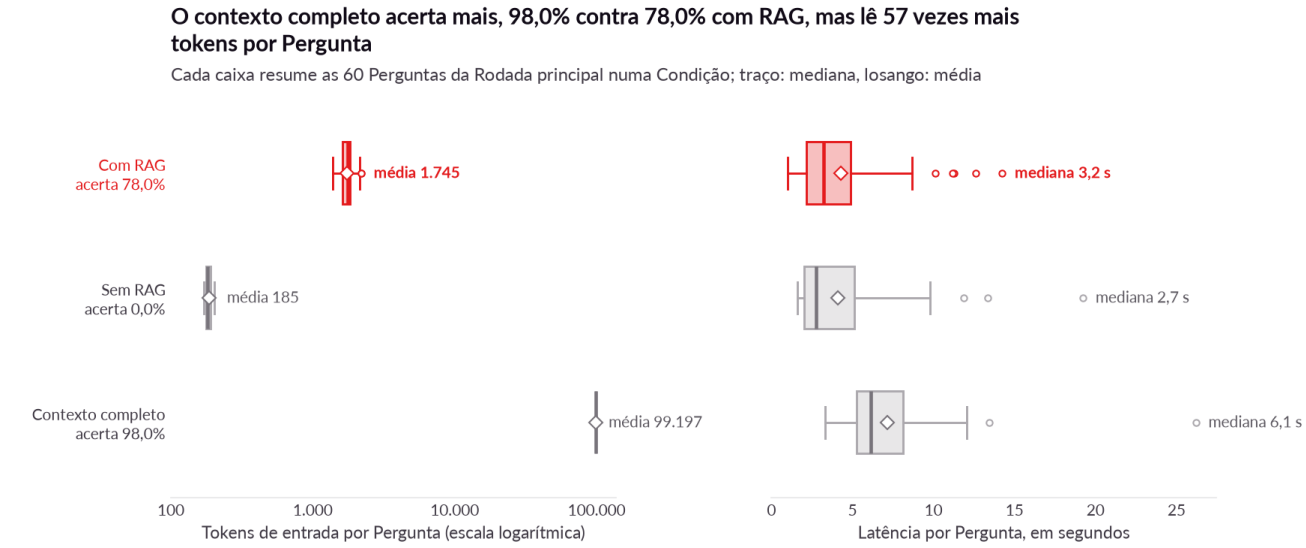
Tabela 4: Custo por Condição na Rodada principal: tokens de entrada em média por Pergunta (inclusive os lidos do cache), latência mediana por Pergunta e respostas dadas por outro modelo que não o pedido (fallback do servidor).

Condição	Tokens de entrada (média)	Latência mediana (s)	Fallbacks
Com RAG	1.745	3,2	0
Sem RAG	185	2,7	0
Contexto completo	99.197	6,1	0

Se cabe no contexto, para que RAG?

Com RAG, cada Pergunta levou em média 1.745 tokens de entrada, com latência mediana de 3,2 s; com o contexto completo, 99.197 tokens e 6,1 s. Entre as duas, o intervalo pareado do Acerto da resposta diz: com RAG acerta menos.

A Figura 3 mostra a distribuição por Pergunta, e não só a média: cada caixa resume as Perguntas de uma Condição, com o acerto ao lado do nome. O eixo dos tokens é logarítmico, porque as Condições diferem em ordens de grandeza.



Fonte: Rodada principal da avaliação do assistente sobre o Relatório-fonte Gestão Hospitalar no SUS-SP, com os Veredictos revisados pelo autor.

Figura 3: Tokens de entrada e latência por Pergunta, por Condição, na Rodada principal, com o Acerto da resposta ao lado de cada Condição. O traço na caixa é a mediana, e o losango, a média.

Na Rodada principal inteira, as três Condições somaram 6.067.592 tokens de entrada e 133.558 de saída. Respostas dadas por um modelo diferente do pedido (fallback do servidor): 0.

8 Variabilidade entre Rodadas

O projeto não fixa a temperatura do modelo, então duas Rodadas iguais podem dar Veredictos diferentes. Para medir isso, a Rodada principal foi repetida, e cada repetição é comparada com ela. O número de repetições comparadas com a Rodada principal é 2. As repetições não passam pela Revisão do autor: a concordância compara os Veredictos automáticos (da regra ou do Juiz) e, para a comparação ser justa, a Rodada principal entra do mesmo jeito, sem a Revisão. A Tabela 5 dá, para cada repetição e Condição, a fração das Perguntas em que o Veredicto foi o mesmo.

Tabela 5: Concordância dos Veredictos automáticos entre cada repetição e a Rodada principal, por Condição, sobre todas as Perguntas comparadas. Veredictos não revisados.

Repetição	Condição	Concordância	Perguntas
Primeira repetição	Com RAG	96,7%	60
Primeira repetição	Sem RAG	100,0%	60
Primeira repetição	Contexto completo	95,0%	60
Segunda repetição	Com RAG	95,0%	60
Segunda repetição	Sem RAG	100,0%	60
Segunda repetição	Contexto completo	96,7%	60

A concordância mede a estabilidade do sistema inteiro, respondedor e Juiz juntos. Qualquer discordância entre Rodadas diz que parte do acerto publicado depende do sorteio do modelo, e é por isso que o número de destaque vem da Rodada revisada, e não da média das Rodadas.

9 Limitações

O que os dados deste Relatório de avaliação não autorizam afirmar:

- **Só texto.** O assistente lê o texto, as tabelas e as legendas do Relatório-fonte, mas não os gráficos: um valor que só existe dentro da imagem de um gráfico não é extraído. As Perguntas que dependeriam deles ficaram fora do Gabarito, e por isso o acerto medido não vale para elas.
- **Amostra pequena.** São 50 Perguntas respondíveis e 10 sem resposta. O intervalo do número de destaque vai de 64,8% a 87,2%, e o cruzamento por Tipo de pergunta tem poucas Perguntas por célula: diferenças entre Tipos são indícios, e não resultados.
- **Um documento.** Tudo foi medido sobre um único Relatório-fonte, em português, com o layout do Relatório-fonte, escrito em LaTeX. O acerto não se transfere para outro documento, outro layout ou outro idioma sem medir de novo.
- **Gabarito proposto com ajuda de um modelo.** As Perguntas e as respostas do Gabarito foram propostas com ajuda de um modelo de linguagem e conferidas pelo autor no Relatório-fonte. A Revisão corrige erros, mas não apaga o viés de escolha: Perguntas que um modelo acha naturais de propor podem ser mais fáceis para um modelo responder.
- **Veredictos revisados por uma pessoa.** Dos 42 Veredictos do Juiz na Rodada principal, 42 foram revisados pelo autor, e a Revisão concordou com o Juiz em todos. A Revisão é de um revisor só, sem medida de concordância entre revisores. O Juiz usou 3 modelos em cadeia, nesta ordem: gemini-3.6-flash, gemini-3-flash-preview e gemini-3.1-flash-lite; quando a cota diária gratuita de um acabava, o seguinte assumia. O respondedor foi o `gemini-3.5-flash-lite`.
- **Repetições não revisadas.** A concordância entre Rodadas usa Veredictos automáticos e mede a estabilidade, e não o acerto.
- **Um modelo.** Os números publicados são de um só modelo, o `gemini-3.5-flash-lite`. O provedor local (Ollama) existe no código, mas não gera número publicado.
- **Custo em tokens.** O custo é medido em tokens de entrada e em latência, e não em dinheiro; a latência depende da carga do servidor no momento da Rodada.

A Como refazer os números

As Rodadas ficam versionadas no repositório, com o commit e os parâmetros de cada execução ao lado. Um comando refaz tudo a partir delas, sem chamar o modelo nem gastar cota:

```
uv run python scripts/reproduzir.py
```

Ele refaz a análise, as figuras, as macros deste Relatório de avaliação, o README e a lista de números canônicos, compila este PDF e roda o conferidor de números, parando no primeiro passo que falhar. Cada número impresso aqui tem uma linha em `NUMEROS_CANONICOS.md`, com o script que o calcula e os lugares onde aparece.